



Análise de Regressão



Sebastião Martins Filho

Fatores do Experimento



Qualitativos



ANOVA



Testes de comparações
múltiplas


Quantitativos




Análise de Regressão

Efeito funcional
entre X e Y

Correlação (Y1,Y2)



Tempo de aquecimento (min)	UFC/mL (Leite de cabra)	UFC/mL (Leite de vaca)
0	86000	incontáveis
5	700	54000
10	103	8000
15	25	2800
20	18	15




Relação funcional (X e Y)

Fatores do Experimento

Verifica a relação funcional entre uma variável dependente e uma ou mais variáveis independentes

X



Y

Variável independente

Variável dependente



Modelo de predição

Escolha do Modelo

Exemplo: modelo linear de 1º grau

Suponha que se deseja saber quanto (5, 10, 15, 20, 25, 30 e 35 mg) de um catalisador devemos utilizar para obtermos maior rapidez em uma reação química.




Figura 1 – Gráfico de dispersão do tempo (min) de uma reação química em função da dose do catalisador




Figura 2 – Ajuste de um modelo de 1º grau para explicar a variação do tempo em função da dose do catalisador

Escolha do Modelo

Exemplo: modelo linear de 2º grau

Suponha que se deseja saber quanto (5, 10, 15, 20, 25, 30 e 35 mg) de um catalisador devemos utilizar para obtermos maior rapidez em uma reação química.




Figura 3 – Gráfico de dispersão do tempo (min) de uma reação química em função da dose do catalisador




Figura 4 – Ajuste de um modelo de 2º grau para explicar a variação do tempo em função da dose do catalisador

Análise de Regressão Linear Simple

$$Y_i = \beta_0 + \beta_1 X_i + e_i$$

Obtenção das
estimativas dos
parâmetros do modelo



Significância do modelo
de regressão

Pressuposições do Modelo

Ao estabelecer o modelo de regressão linear simples, pressupomos que:


- 1) A relação entre X e Y é linear;
- 2) Os valores de X são fixos, isto é, X não é uma variável aleatória;
- 3) A média do erro é nula, isto é, $E(e_i)=0$;
- 4) Para um dado valor de X, a variância do erro e_i é sempre σ^2 , denominada variância residual. Dizemos então que o erro é homocedástico.
- 5) O erro de uma observação é não correlacionado com o erro em outra observação;
- 6) Os erros têm distribuição normal.

Pelas pressuposições 3, 4 e 6, temos:

$$e_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Pressuposições do Modelo

$$e_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$




iid – independentes e identicamente distribuídos

Obtenção dos Estimadores - MMQ

$$Y_i = \beta_0 + \beta_1 X_i + e_i$$


Método de Mínimos Quadrados



$$z = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$

Minimizar a SQerros

Obtenção dos Estimadores - MMQ




$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n [Y_i - \beta_0 - \beta_1 X_i]^2$$

$$\begin{cases} \frac{\partial \sum_{i=1}^n e_i^2}{\partial \beta_0} = 0 \\ \frac{\partial \sum_{i=1}^n e_i^2}{\partial \beta_1} = 0 \end{cases}$$

$$\begin{cases} \sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i \\ \sum_{i=1}^n Y_i X_i = \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 \end{cases}$$

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

Interpretação dos Estimadores



β_0 (intercepto); quando a região experimental inclui $X=0$, β_0 é o valor da média da distribuição de Y em $X=0$, caso contrário, não tem um significado prático;

β_1 (inclinação) expressa a *taxa de mudança* em Y , isto é, é a mudança em Y quando ocorre a mudança de uma unidade em X . Ele indica a mudança na média da distribuição de probabilidade de Y por unidade de acréscimo em X .

Exemplo - 1

O modelo linear foi proposto para explicar a relação entre a quantidade de ração fornecida e produção de leite por cabras. Pede-se por meio dos dados abaixo, verificar se a ração influencia significativamente a produção de leite ($\alpha = 5\%$)

Níveis de ração (g)	50	75	100	125	150
Produção de leite (L/dia)	1,2	1,7	2,0	2,1	2,5

$$\sum_{i=1}^5 X_i = 500$$

$$\sum_{i=1}^5 X_i^2 = 56250,00$$

$$\sum_{i=1}^5 X_i Y_i = 1025,00$$

$$\sum_{i=1}^5 Y_i = 9,50$$

$$\sum_{i=1}^5 Y_i^2 = 18,99$$

$$\bar{X} = 100 \quad \bar{Y} = 1,90$$

$$\sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i \rightarrow 5\hat{\beta}_0 + 500\hat{\beta}_1 = 9,50$$

$$\sum_{i=1}^n Y_i X_i = \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 \rightarrow 500\hat{\beta}_0 + 56250\hat{\beta}_1 = 1025$$



Exemplo – Equação da Regressão

$$\begin{cases} 5\hat{\beta}_0 + 500\hat{\beta}_1 = 9,50 \\ 500\hat{\beta}_0 + 56250\hat{\beta}_1 = 1025 \quad (\div 100) \end{cases} \longrightarrow \begin{cases} 5\hat{\beta}_0 + 500\hat{\beta}_1 = 9,50 & \text{Eq.1} \\ 5\hat{\beta}_0 + 562,50\hat{\beta}_1 = 10,25 & \text{Eq.2} \end{cases}$$

Fazendo eq.2 – eq.1

$$\begin{cases} 5\hat{\beta}_0 + 500\hat{\beta}_1 = 9,50 \\ 62,50\hat{\beta}_1 = 0,75 \end{cases} \longrightarrow \hat{\beta}_1 = \frac{0,75}{62,50} = 0,0120$$

Substituindo $\hat{\beta}_1$ na eq.1

$$5\hat{\beta}_0 + 500 * 0,0120 = 9,50$$

$$5\hat{\beta}_0 = 9,50 - 6,00$$

$$\hat{\beta}_0 = 0,7000$$

$$\hat{Y}_i = 0,7000 + 0,0120 X_i$$



Exemplo – Interpretação dos Parâmetros



Níveis de ração (g)	50	75	100	125	150
Produção de leite (L/dia)	1,2	1,7	2,0	2,1	2,5

$$\hat{Y}_i = 0,7000 + 0,0120 X_i$$



Se o consumo de ração for igual a “zero” grama, a cabra produzirá 0,70 litro de leite por dia



β_0 representará somente uma média (correção), pois o nível “zero grama” não faz parte da faixa estudada.



Exemplo – Interpretação dos Parâmetros



Níveis de ração (g)	50	75	100	125	150
Produção de leite (L/dia)	1,2	1,7	2,0	2,1	2,5

$$\hat{Y}_i = 0,7000 + 0,0120 X_i$$



A variação de um grama de ração acarretará um aumento 0,012 litro na produção de leite por dia



Exemplo – Predição de Valores

Quanto de leite a cabra produzirá se for alimentada com 90g de ração???

Níveis de ração (g)	50	75	100	125	150
Produção de leite (L/dia)	1,2	1,7	2,0	2,1	2,5

90 g

$$\hat{Y}_i = 0,7000 + 0,0120 X_i$$



Exemplo – Predição de Valores

Quanto de leite a cabra produzirá se for alimentada com 170g de ração???

Níveis de ração (g)	50	75	100	125	150
Produção de leite (L/dia)	1,2	1,7	2,0	2,1	2,5

↑
170 g

~~$$\hat{Y}_i = 0,7000 + 0,0120 X_i$$~~



Exemplo – Desvios da Regressão

Níveis de ração (g)	50	75	100	125	150
Produção de leite (L/dia)	1,2	1,7	2,0	2,1	2,5

$$Y_i = \beta_0 + \beta_1 X_i + e_i \text{ Observados}$$

Estimados $\hat{Y}_i = 0,7000 + 0,0120 X_i$


$\hat{e}_i = Y_i - \hat{Y}_i \rightarrow \text{Desvios}$

Para 75g de ração

$$\hat{Y}_i = 0,70 + 0,012(75) = 1,60 \text{ L /dia}$$

$$Y_i = 1,70 \text{ L /dia}$$

$$\hat{e}_i = Y_i - \hat{Y}_i = 1,70 - 1,60 = 0,10$$



Análise de Regressão Linear Simples

$$Y_i = \beta_0 + \beta_1 X_i + e_i$$

Obtenção das
estimativas dos
parâmetros do modelo



Significância do modelo
de regressão

Significância do Modelo

Análise de Variância

$$H_0 : \beta_1 = 0$$

$$H_a : \beta_1 \neq 0$$

FV	GL	SQ	QM	F cal	F tab
Regressão	p	SQ reg	SQ reg / p	QM reg / QM ind	(p; n - 1 - p)
Independente da regressão	n - 1 - p	SQ ind	SQ ind / n - 1 - p		
Total	n-1	SQ total			

$$SQ_{reg} = \widehat{\beta}_0 \sum_{i=1}^n Y_i + \widehat{\beta}_1 \sum_{i=1}^n X_i Y_i - \frac{(\sum Y_i)^2}{n}$$

$$\sum_{i=1}^5 Y_i = 9,50$$

$$SQ_{total} = \sum_{i=1}^n Y_i^2 - \frac{(\sum Y_i)^2}{n}$$

$$\sum_{i=1}^5 Y_i^2 = 18,99$$

$$SQ_{ind} = SQ_{total} - SQ_{reg}$$

$$\sum_{i=1}^5 X_i Y_i = 1025,00$$

Significância do Modelo

$$SQ_{total} = \sum_{i=1}^n Y_i^2 - \frac{(\sum Y_i)^2}{n}$$

$$\hat{\beta}_0 = 0,7000$$

$$\hat{\beta}_1 = 0,0120$$

$$\sum_{i=1}^5 Y_i = 9,50$$

$$\sum_{i=1}^5 Y_i^2 = 18,99$$

$$\sum_{i=1}^5 X_i Y_i = 1025,00$$

$$SQ_{total} = 18,99 - \frac{9,50^2}{5} = 0,9400$$

$$SQ_{reg} = \hat{\beta}_0 \sum_{i=1}^n Y_i + \hat{\beta}_1 \sum_{i=1}^n X_i Y_i - \frac{(\sum Y_i)^2}{n}$$

$$SQ_{reg} = 0,70 * 9,50 + 0,0120 * 1025,00 - \frac{9,50^2}{5}$$

$$SQ_{reg} = 0,9000$$

$$SQ_{ind} = SQ_{total} - SQ_{reg}$$

$$SQ_{ind} = 0,94 - 0,90 = 0,0400$$

Análise de Variância

$$H_0 : \beta_1 = 0$$

$$H_a : \beta_1 \neq 0$$

Níveis de ração (g)	50	75	100	125	150
Produção de leite (L/dia)	1,2	1,7	2,0	2,1	2,5

$$\hat{Y}_i = 0,7000 + 0,0120 X_i$$

FV	GL	SQ	QM	F cal	F tab (5%)
Regressão	1	0,90	0,9000	67,67*	(1; 3) = 10,13
Independente da regressão	3	0,04	0,0133		
Total	4	0,94			

* p-valor < 0,05

$$F_{cal} \geq F_{tab} \rightarrow \text{Rejeita-se } H_0$$

A variável independente influencia significativamente a variável dependente (resposta) ao nível de 5% de probabilidade.



Coeficiente de Determinação

Quanto da variação total está sendo explicada pelo modelo?


$$r^2 = \frac{SQ_{REG}}{SQ_{TOTAL}} 100$$
$$r^2 = \frac{0,90}{0,94} 100 = 95,74\%$$

95,74% da variação total em Y está sendo explicada pelo modelo de regressão.

A regressão será tanto mais útil quanto mais próximo de 100% estiver o valor de r^2 .

Coeficiente de Determinação Ajustado

- A inclusão de inúmeras variáveis, mesmo que tenham muito pouco poder explicativo, aumentarão o valor do r^2 .
- O r^2 ajustado penaliza a inclusão de regressores pouco explicativos.

Coeficiente de
determinação
ajustado


$$r_a^2 = 1 - \frac{n - 1}{n - k} (1 - r^2)$$

n = número de observações

k = número de parâmetros do modelo (constante + coeficientes)

$$r_a^2 = 1 - \frac{5 - 1}{5 - 2} (1 - 0,9574)$$


$$r_a^2 = 0,9432 = 94,32\%$$

$$\begin{cases} n = 4 \\ r^2 = 0,6 \\ k = 3 \end{cases}$$

Excluindo o caso em que $r^2=1$, temos que $r_a^2 < r^2$. Note que r_a^2 pode ser negativo.

Coeficiente de Variação

Um outro indicador da qualidade do ajustamento obtido é o coeficiente de variação (CV).


$$CV = \frac{\sqrt{QMInd.}}{\bar{Y}} 100$$
$$CV = \frac{\sqrt{0,0133}}{1,90} 100 = 6,07\%$$

O resultado é tanto melhor quanto menor for o CV.

Exemplo - 2

Introduziu-se uma nova ração com o objetivo de aumentar a produção de leite para 2,0 litros por dia

Níveis de ração (g)	50	75	100	125	150
Produção de leite (L/dia)	2,3	2,0	1,8	2,1	1,8

$$\hat{Y}_i = 2,3600 - 0,0036 X_i$$

FV	GL	SQ	QM	F cal	F tab (5%)
Regressão	1	0,0810	0,0810	2,45 ^{1/}	(1; 3) = 10,13
Independente da regressão	3	0,0990	0,0330		
Total	4	0,1800			

$$\left\{ \begin{array}{l} H_0 : \beta_1 = 0 \\ H_a : \beta_1 \neq 0 \end{array} \right.$$

^{1/}p-valor > 0,05

$$F_{cal} \leq F_{tab}$$



Não se Rejeita H_0

A variável independente não influencia a variável dependente (resposta).

