




UNIVERSIDADE FEDERAL DE VIÇOSA
DEPARTAMENTO DE ESTATÍSTICA
EST 220 – ESTATÍSTICA EXPERIMENTAL


Análise de Regressão



Sebastião Martins Filho

Regressão Polinomial

- A regressão polinomial pode ser vista como uma generalização da regressão linear, necessitando adaptar o ajuste para uma função polinomial de grau superior.
- Se I é o número de níveis do fator quantitativo, o ajuste do polinômio deve ser no máximo grau $(I - 1)$



Função Polinomial de grau p
$$y = \beta_0 + \beta_1 x^1 + \beta_2 x^2 + \dots + \beta_p x^p + \varepsilon$$


Estimação dos parâmetros

Obter $\beta_0, \beta_1, \dots, \beta_p$, tais que $\sum \epsilon^2$ seja mínima


$$\sum \epsilon^2 = \sum [y_i - (\beta_0 + \beta_1 x^1 + \beta_2 x^2 + \dots + \beta_p x^p)]^2$$

Solução de Mínimos Quadrados

$$\left. \begin{array}{l} \frac{\partial \sum \epsilon^2}{\partial \beta_0} = 0 \\ \frac{\partial \sum \epsilon^2}{\partial \beta_1} = 0 \\ \vdots \\ \frac{\partial \sum \epsilon^2}{\partial \beta_p} = 0 \end{array} \right\} \Rightarrow \hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$$



Regressão de 2º Grau



$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X + \hat{\beta}_2 X^2$$

Modelo de segunda ordem

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$$

β_0 : constante da regressão;

β_1 : coeficiente do termo linear da regressão

β_2 : coeficiente do termo quadrático da regressão

ε_i : erro da regressão associado ao valor observado Y_i

$$\begin{cases} \sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i + \hat{\beta}_2 \sum_{i=1}^n X_i^2 \\ \sum_{i=1}^n Y_i X_i = \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 + \hat{\beta}_2 \sum_{i=1}^n X_i^3 \\ \sum_{i=1}^n Y_i X_i^2 = \hat{\beta}_0 \sum_{i=1}^n X_i^2 + \hat{\beta}_1 \sum_{i=1}^n X_i^3 + \hat{\beta}_2 \sum_{i=1}^n X_i^4 \end{cases}$$

Equações de mínimos quadrados

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X + \hat{\beta}_2 X^2$$

Exercício

De acordo com os dados fornecidos abaixo para a variável X (dose do micronutriente Zn em ppm) e a variável Y (matéria seca em g/planta), verifique, usando o nível de 5% de probabilidade e o modelo linear de 2º grau, se a relação entre as variáveis X (independente) e Y (dependente) é significativa.

X	1,0	2,5	4,0	5,5	7,0	8,5
Y	20,3	31,3	34,6	35,1	30,2	19,7

$$\sum X_i$$

$$\sum X_i^2$$

$$\sum X_i^3$$

$$\sum X_i^4$$

$$\begin{cases} \sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i + \hat{\beta}_2 \sum_{i=1}^n X_i^2 \\ \sum_{i=1}^n Y_i X_i = \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 + \hat{\beta}_2 \sum_{i=1}^n X_i^3 \\ \sum_{i=1}^n Y_i X_i^2 = \hat{\beta}_0 \sum_{i=1}^n X_i^2 + \hat{\beta}_1 \sum_{i=1}^n X_i^3 + \hat{\beta}_2 \sum_{i=1}^n X_i^4 \end{cases}$$

$$\sum Y_i$$

$$\sum Y_i^2$$

$$\sum XY$$

$$\sum YX^2$$

Exercício

De acordo com os dados fornecidos abaixo para a variável X (dose do micronutriente Zn em ppm) e a variável Y (matéria seca em g/planta), verifique, usando o nível de 5% de probabilidade e o modelo linear de 2º grau, se a relação entre as variáveis X (independente) e Y (dependente) é significativa.

X	1,0	2,5	4,0	5,5	7,0	8,5
Y	20,3	31,3	34,6	35,1	30,2	19,7

$$\sum X_i = 28,50$$

$$\sum X_i^2 = 174,75$$

$$\sum X_i^3 = 1204,125$$

$$\sum X_i^4 = 8832,1875$$

$$\begin{cases} \sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i + \hat{\beta}_2 \sum_{i=1}^n X_i^2 \\ \sum_{i=1}^n Y_i X_i = \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 + \hat{\beta}_2 \sum_{i=1}^n X_i^3 \\ \sum_{i=1}^n Y_i X_i^2 = \hat{\beta}_0 \sum_{i=1}^n X_i^2 + \hat{\beta}_1 \sum_{i=1}^n X_i^3 + \hat{\beta}_2 \sum_{i=1}^n X_i^4 \end{cases}$$

$$\sum Y_i = 171,20$$

$$\sum Y_i^2 = 5121,08$$

$$\sum XY = 808,85$$

$$\sum YX^2 = 4734,425$$

Exercício

$$\begin{cases} \sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i + \hat{\beta}_2 \sum_{i=1}^n X_i^2 \\ \sum_{i=1}^n Y_i X_i = \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 + \hat{\beta}_2 \sum_{i=1}^n X_i^3 \\ \sum_{i=1}^n Y_i X_i^2 = \hat{\beta}_0 \sum_{i=1}^n X_i^2 + \hat{\beta}_1 \sum_{i=1}^n X_i^3 + \hat{\beta}_2 \sum_{i=1}^n X_i^4 \end{cases}$$

$$171,20 = 6 \hat{\beta}_0 + 28,50 \hat{\beta}_1 + 174,75 \hat{\beta}_2 \quad \div 6$$

$$808,85 = 28,50 \hat{\beta}_0 + 174,75 \hat{\beta}_1 + 1204,125 \hat{\beta}_2 \quad \div 28,50$$

$$4734,425 = 174,75 \hat{\beta}_0 + 1204,125 \hat{\beta}_1 + 8832,1875 \hat{\beta}_2 \quad \div 174,75$$

$$\sum X_i = 28,50 \quad \sum X_i^2 = 174,75 \quad \sum X_i^3 = 1204,125 \quad \sum X_i^4 = 8832,1875$$

$$\sum Y_i = 171,20 \quad \sum Y_i^2 = 5121,08 \quad \sum XY = 808,85 \quad \sum YX^2 = 4734,425$$

$$\bar{X} = 4,75 \quad \bar{Y} = 2853$$

Exercício

$$\hat{\beta}_0 + 4,7500 \hat{\beta}_1 + 29,1250 \hat{\beta}_2 = 28,5333$$

$$\hat{\beta}_0 + 4,7500 \hat{\beta}_1 + 29,1250 \hat{\beta}_2 = 28,5333$$

$$\hat{\beta}_0 + 6,1316 \hat{\beta}_1 + 42,2500 \hat{\beta}_2 = 28,3807 \xrightarrow{(2-1)}$$

$$1,3816 \hat{\beta}_1 + 13,1250 \hat{\beta}_2 = -0,1526$$

$$\hat{\beta}_0 + 6,8906 \hat{\beta}_1 + 50,5418 \hat{\beta}_2 = 27,0926 \xrightarrow{(3-2)}$$

$$0,7590 \hat{\beta}_1 + 8,2918 \hat{\beta}_2 = -1,2881$$

$x(1,8203)$
 $(3-2)$

$$\hat{\beta}_0 + 4,7500 \hat{\beta}_1 + 29,1250 \hat{\beta}_2 = 28,5333$$


$$1,3816 \hat{\beta}_1 + 13,1250 \hat{\beta}_2 = -0,1526$$

$$1,9686 \hat{\beta}_2 = -2,1921 \Rightarrow \hat{\beta}_2 = -1,1135$$

$$\text{Substituindo } \hat{\beta}_2 \text{ na eq. 2} \Rightarrow \hat{\beta}_1 = 10,4676$$

$$\text{Substituindo } \hat{\beta}_1 \text{ e } \hat{\beta}_2 \text{ na eq. 1} \Rightarrow \hat{\beta}_0 = 11,2429$$

$$\hat{Y}_i = 11,2429 + 10,4676 X_i - 1,1135 X_i^2$$



Análise de Variância

$$\begin{cases} H_0: \beta_1 = \beta_2 = 0 \\ H_a: \beta_i \neq 0 \end{cases}$$

FV	GL	SQ	QM	F cal	F tab
Regressão	p	SQ reg	SQ reg / p	QM reg / QM ind	(p; n - 1 - p)
Independente da regressão	n - 1 - p	SQ ind	SQ ind / n - 1 - p		
Total	n-1	SQ total			

$$SQ_{Regressão} = \hat{\beta}_0 \sum_{i=1}^n Y_i + \hat{\beta}_1 \sum_{i=1}^n Y_i X_i + \hat{\beta}_2 \sum_{i=1}^n Y_i X_i^2 - \frac{\left(\sum_{i=1}^n Y_i \right)^2}{n}$$

$$SQ_{Total} = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i \right)^2}{n}$$

$$SQ_{ind} = SQ_{total} - SQ_{reg}$$

Análise de Variância

$$SQ_{Total} = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n}$$

$$\hat{\beta}_0 = 11,2429$$

$$\hat{\beta}_1 = 10,4676$$

$$\hat{\beta}_2 = -1,1135$$

$$\sum Y_i = 171,20$$

$$\sum XY = 808,85$$

$$\sum YX^2 = 4734,425$$

$$\sum Y_i^2 = 5121,08$$

$$SQ_{Total} = 5121,08 - \frac{171,20^2}{6} = 236,1733$$

$$SQ_{Regressão} = \hat{\beta}_0 \sum_{i=1}^n Y_i + \hat{\beta}_1 \sum_{i=1}^n Y_i X_i + \hat{\beta}_2 \sum_{i=1}^n Y_i X_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n}$$

$$SQ_{Reg} = 11,2429 * 171,20 + 10,4676 * 808,85 - 1,1135 * 4734,4250 - \frac{171,20^2}{6}$$

$$SQ_{Reg} = 234,8139$$

$$SQ_{ind} = SQ_{total} - SQ_{reg}$$

$$SQ_{ind} = 236,1733 - 234,8139 = 1,3594$$

Análise de Variância

$$\begin{cases} H_0: \beta_1 = \beta_2 = 0 \\ H_a: \beta_i \neq 0 \end{cases}$$

FV	GL	SQ	QM	F cal	F tab
Regressão	2	234,8139	117,4070	259,10*	9,55
Independente da regressão	3	1,3594	0,4531		
Total	5	236,1733			

* p-valor < 0,05

$$F_{cal} \geq F_{tab} \Rightarrow \text{Rejeita-se } H_0$$

$$\hat{Y}_i = 11,2429 + 10,4676 X_i - 1,1135 X_i^2$$

A variável independente influencia significativamente a variável dependente (resposta), com efeito de 2º grau (parabólico), ao nível de 5% de probabilidade.

Análise de Variância

FV	GL	SQ	QM	F cal	F tab
Regressão	(2)	(234,8150)	117,4075		
Regressão Linear Simples	1	0,4806	0,4810	1,06	10,13
Regressão Quadrática	1	234,3344	234,3340	517,18*	10,13
Independente da regressão	3	1,3584	0,4531		
Total	5	236,1734			

* p-valor < 0,05

$$F_{cal} \geq F_{tab} \Rightarrow \text{Rejeita-se } H_0$$

$$\hat{Y}_i = 11,2429 + 10,4676 X_i - 1,1135 X_i^2$$

A variável independente influencia significativamente a variável dependente (resposta), com efeito de 2º grau (parabólico), ao nível de 5% de probabilidade.

Quanto da variação total está sendo explicada pelo modelo???

Coeficiente de
determinação


$$R^2 = \frac{SQ_{REG}}{SQ_{TOTAL}} 100$$

$$R^2 = \frac{234,8139}{236,1733} 100 = 99,42\%$$

99,42% da variação total dos dados está sendo explicada pelo modelo de regressão.

Coeficiente de Determinação Ajustado

- A inclusão de inúmeras variáveis, mesmo que tenham muito pouco poder explicativo, aumentará o valor do r^2 .
- O r^2 ajustado penaliza a inclusão de regressores pouco explicativos.

Coeficiente de
determinação
ajustado


$$R_a^2 = 1 - \frac{n - 1}{n - k} (1 - r^2)$$

n = número de observações

k = número de parâmetros do modelo (constante + coeficientes)

$$R_a^2 = 1 - \frac{6 - 1}{6 - 3} (1 - 0,9942)$$

$$R_a^2 = 0,9903 = 99,03\%$$

Predição

Para qual dose de micronutriente teremos uma produção máxima?

$$\hat{Y}_i = 11,2429 + 10,4676 X_i - 1,1135 X_i^2$$

Fazer a primeira derivada = 0

$$\frac{\partial \hat{Y}_i}{\partial X_i} = 10,4676 - 2 \cdot (1,1135 X_i) = 0$$

$$10,4676 - 2,2270 X_i = 0$$

$$X_i = 4,7 \text{ ppm} \longrightarrow \text{Ponto crítico}$$

Fazer a segunda derivada

$$\frac{\partial^2 \hat{Y}_i}{\partial^2 X_i} \begin{cases} < 0 & \text{Ponto de máximo} \\ > 0 & \text{Ponto de mínimo} \\ = 0 & \text{Ponto de sela} \end{cases}$$



$$\frac{\partial^2 \hat{Y}_i}{\partial^2 X_i} = -2,2270 < 0$$

Ponto de máximo

Produção máxima

$$\hat{Y}_i = 11,2429 + 10,4676 \times 4,7 - 1,1135 \times 4,7^2$$


$$\hat{Y}_i = 35,89 \text{ gramas}$$



Exemplo 1

$\alpha = 0,05$

X



Y

Variável independente

doses de nutriente

Variável dependente

Produção de milho

$$\hat{Y}_i = 2,4219 + 1,3672X_i$$

FV	GL	p-valor
Regressão	1	0,0361
Ind.	8	
TOTAL	9	

$$\hat{Y}_i = 1,3967 + 3,4257X_i - 1,2593X_i^2$$

FV	GL	p-valor
Regressão	2	0,4361
Ind.	7	
TOTAL	9	


Qual deve ser a recomendação dada ao agrônomo?



Exemplo 2

$\alpha = 0,05$

X



Y

Variável independente

Ração (g)

Variável dependente

Teor de ferro na carne bovina
Atender o limite inferior de
especificação (6 mg)

$$\hat{Y}_i = 2,68753 + 1,3657X_i$$

FV	GL	p-valor
Regressão	1	0,5524
Ind.	8	
TOTAL	9	

$$\hat{Y}_i = 0,3269 + 5,1100X_i - 1,2749X_i^2$$

FV	GL	p-valor
Regressão	2	0,0264
Ind.	7	
TOTAL	9	

**Qual deve ser a recomendação
dada ao zootecnista?**

